

PREVISÃO DE GERAÇÃO FOTOVOLTAICA DE CURTO PRAZO: UM ESTUDO DE CASO UTILIZANDO ENCODER-DECODER LSTM

RESUMO

Devido aos efeitos sentidos pelas mudanças climáticas, há uma comoção mundial pelo fim das emissões de gás carbônico, para isso diversos incentivos estão sendo realizados para promover a utilização disseminada de recursos oriundos de fontes renováveis, sendo o recurso solar uma peça fundamental nessa transição. A utilização de um recurso intermitente gera diversos desafios para o sistema de transmissão de energia, uma alternativa para contornar essa dificuldade é a utilização de modelos de previsão como ferramenta de gestão para operação da distribuição de energia. Modelos não paramétricos surgem como alternativa para previsões intra hora e intra dia, uma vez que utilizam de séries históricas e durante seu treinamento aprendem a relacionar esses dados e suas incertezas com o alvo desejado. Com base nisso, utilizamos um modelo conhecido como Encoder-Decoder LSTM para previsão da potência de geração fotovoltaica para horizonte de três horas com resolução horária. Foram avaliados dois conjuntos de atributos de entrada, sendo um deles somente com atributos atmosféricos e outro utilizando da série histórica da potência junto com alguns dados da geometria Sol-Terra. Os testes mostraram vantagem do utilizando dados históricos de potência como atributo de entrando, sendo o único que obteve valor de *skill score* positivo nos três horizontes de previsão sendo 13,67%, 37,51% e 54,51% e RMSE de 4,46%, 5,67% e 6,15%.

Palavras-Chave: Previsão Energia Solar, Encoder-Decoder LSTM, Sustentabilidade Energética.

ABSTRACT

The effects of climate change have prompted a global effort to reduce carbon dioxide emissions. To this end, various incentives are being implemented to promote the widespread use of resources derived from renewable sources, with solar power representing a key element in this transition. The intermittent nature of solar power presents a number of challenges for the energy transmission system. One potential solution is to utilize forecasting models as a management tool to operate energy distribution. Non-parametric models have emerged as an alternative for intra-hour and intra-day forecasts, as they utilize time series during their training to relate the data and its uncertainties to the desired target. Based on this, we employed a model known as the LSTM Encoder-Decoder to forecast photovoltaic generation power for a three-hour horizon with hourly resolution. Two types of input attributes were evaluated: one that utilized only atmospheric attributes and the other that combined the historical power series with certain data pertaining to the Sun-Earth geometry. The tests demonstrated the superiority of historical power data as an input attribute, as it was the sole one to achieve a positive skill score for the three forecast horizons, namely 13.67%, 37.51% and 54.51%, and RMSEs of 4.46%, 5.67% and 6.15%.

Keywords: Solar Energy Forecast, LSTM Encoder-Decoder, Energy Sustainability.



1. INTRODUÇÃO

A geração de energia fotovoltaica vem crescendo no mundo devido aos pactos mundiais para redução e fim das emissões de carbono na atmosfera e assim desacelerar os impactos gerados pelas mudanças climáticas. Com isso, países estão investindo e incentivando a utilização de fontes renováveis para geração de energia e o recurso solar vem recebendo grande destaque. Segundo o infográfico número 67 da ABSOLAR (2024), a geração fotovoltaica já ocupa a segunda posição da matriz energética brasileira com 18,2%, perdendo apenas para a geração hídrica. Contudo a flutuação diária da irradiação solar em escalas de tempo de médio e curto prazo causada pelo deslocamento de nuvens é um dos principais desafios para a operação.

No Brasil, o SIN (Sistema Interligado Nacional) é responsável por conectar e transmitir a energia elétrica de modo a abastecer quase todo o território. A adição de energia elétrica proveniente dos recursos intermitentes traz desafios à integração ao sistema. A utilização de técnicas de previsão desses recursos ou de sua geração surgem como solução para auxiliar na operação e possibilita a redução de custos de operação com sistemas de mitigação (Almeida, 2017).

Dentre as técnicas de previsão de geração fotovoltaica, há a abordagem paramétrica, no qual são utilizados modelos físico-matemáticos com dados de previsão meteorológica como atributos de entrada. A principal vantagem desse tipo do modelo está relacionado à possibilidade de utilizá-los antes do início da operação do sistema. Outra técnica utilizada em modelos não paramétricos, baseia-se em séries históricas de variáveis atmosféricas e operacionais do próprio gerador. Esta segunda técnica é refém da qualidade dos dados medidos, o que pode aumentar as incertezas das previsões. A principal restrição dos modelos não paramétricos é a necessidade que o sistema já esteja operando por um tempo, contudo o modelo aprende a relacionar as incertezas dos dados de entrada com o valor correto da saída durante o treinamento. Dentre os modelos não paramétricos destacam-se técnicas estatísticas como os modelos regressivos e modelos baseados em aprendizado de máquina e aprendizado profundo (*machine learning* e *deep learning*).

A escolha do modelo parte de variáveis que são relacionadas ao horizonte de previsão e à resolução espacial. Para horizonte de previsão intra-horário e intradia com



resolução espacial de até 1km, modelos estatísticos surgem como melhor opção, já para horizontes de dias seguintes com resolução espacial maiores do que 1km, os modelos paramétricos desempenham melhor (Diagne, et. al. 2013). Dentre as técnicas citadas, modelos baseados em *deep learning* tem ganhado espaço pela possibilidade de processar sequência de dados de entrada e gerar nova sequência como saída, problema conhecido como *seq2seq*. Rajagukguk, Ramadhan e Lee (2020) estudaram a aplicação de diferentes modelos de *deep learning* para previsão do recurso solar e da geração fotovoltaica, dentre os resultados obtidos o destaque ficou para os modelos LSTM (*Long Short Term Memory*) e GRU (*Gated Recurrent Units*), por apresentarem melhor desempenho. Goodfellow, Yoshua e Aaron (2016) destacam a utilização de uma arquitetura chamada Encoder-Decoder LSTM que tem aplicações para tradução de textos. Estudos internacionais foram realizados aplicando esse mesmo modelo (Sabri; El Hassouni, 2023).

Com base nisso, esse trabalho aplicou o modelo Encoder-Decoder LSTM para uma planta em operação na Cidade Universitária da USP, na região metropolitana de São Paulo, para horizonte de previsão de até 3 horas com resolução horária. Além disso, avaliamos a utilização de dois grupos de atributos de entrada sendo um deles somente com dados meteorológicos e o outro utilizando da série histórica de potência do gerador fotovoltaico.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 Local de estudo

O local selecionado para desenvolvimento do trabalho é um gerador fotovoltaico instalado na Cidade Universitária da USP, localizada na região metropolitana de São Paulo. A região é a mais populosa do Brasil e recebe irradiação global horizontal média de 4,7 Wh/m².dia (Pereira et al., 2017). Os meses de novembro a abril são caracterizados por serem os mais chuvosos da região, enquanto os meses de maio a outubro são os mais secos. Vale destacar que os meses secos contêm maior concentração de aerossóis atmosféricos, sendo responsável por modificar o espectro da radiação solar nos dias com poucas nuvens (Bet et. al., 2022), sendo um desafio extra para o treinamento do modelo.



2.2 Base de dados e tratamentos

A base de dados foi composta pela junção de três grupos de dados. O primeiro grupo é composto pelos dados de geração fotovoltaica. O segundo é composto por dados de uma estação meteorológica localizada a aproximadamente 140 metros do gerador, no Laboratório de Sistemas Fotovoltaicos (LSF-IEE-USP) que realiza medições horárias da temperatura ambiente (°C), umidade relativa (%), velocidade do vento (m/s), pressão barométrica (mmHg), precipitação (mm), irradiação global (tanto na horizontal quanto no plano inclinado em 27°) (ambas em Wh/m²) e irradiação horizontal difusa (em Wh/m²). Por fim, o último grupo é composto pelos ângulos zenital e azimutal da geometria Sol-Terra. Os anos utilizados para criação da base de dados são de 2018 a 2021.

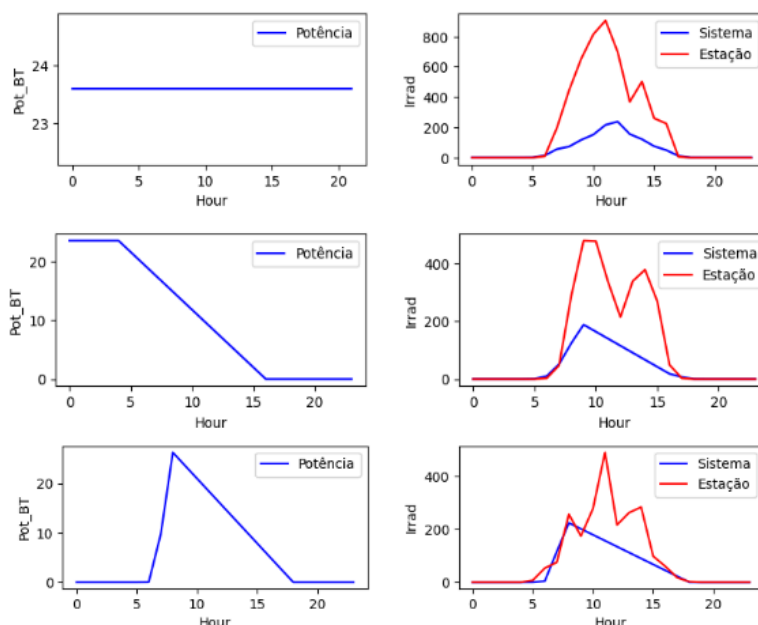
No que se refere aos dados de geração fotovoltaica obtidos pelo SCADA, foi necessário realizar uma conversão, uma vez que os dados são medidos na resolução de minutos (P_{min}). Para isso foi aplicado a Eq. 1, para que fossem convertidos em valor de energia média horária (E_h).

$$E_h = \frac{1}{60} \int_h^{h+59} P_{min} dt \quad (1)$$

Também foi realizada uma avaliação minuciosa da base a fim de identificar ruídos, sendo encontrados dados suspeitos de potência fotovoltaica. Devido a isso, foi desenvolvido um algoritmo que avalia os dados em duas condições, inicialmente são procurados dados diferentes de zero em períodos noturno, posteriormente é contabilizada a quantidade de medições realizadas em períodos com presença de Sol, sendo esperado 14 medições diferentes entre si. Dias que fugiam do padrão esperado por esse algoritmo foram separados para avaliação gráfica e removidos posteriormente se comportamento anômalo fosse confirmado. A Figura 1 apresenta alguns exemplos dos quais foram identificados e removidos pelo algoritmo.



Figura 1. Ruídos de potência identificados e removidos da base de dados



Fonte: Autoria própria

2.3 Modelos utilizados

O modelo utilizado no desenvolvimento do trabalho é o Encoder-Decoder LSTM que é a união entre modelos do tipo LSTM com a arquitetura de rede Encoder-Decoder. Esse modelo tem sua principal utilização em problemas que utilizem uma sequência como entrada e resulta em outra sequência como saída (*seq2seq*), podendo elas ter comprimento variado. Os modelos LSTM são redes neurais do tipo RNR (Redes Neurais Recorrentes), sua topologia foi proposta por Hochreiter e Schmidhuber (1997) e conta com uma estrutura interna que atua como uma memória, permitindo que o modelo capte a autocorrelação dos dados e selecione as informações mais relevantes para que sejam propagadas.

A arquitetura Encoder-Decoder é a junção de duas estruturas, a primeira conhecida como encoder cuja função é codificar a informação de entrada para um vetor latente, a ideia é que esse modelo absorva as dependências temporais entre os elementos da sequência de entrada e reduza a dimensionalidade de forma que possa ser utilizada para geração da saída. O outro é conhecido como decoder cuja função é descomprimir a informação codificada pelo encoder para gerar a sequência de saída do atributo alvo



(Goodfellow; Yoshua; Aaron, 2016). Ambos os modelos são compostos por células LSTM e são treinados simultaneamente.

2.4 Modelo de persistência

Para avaliar a performance do modelo Encoder-Decoder LSTM, foi desenvolvido um modelo de persistência. O modelo de persistência baseia-se em assumir que a condição atmosférica mais recente persiste para os horizontes de previsão. Para tanto, faz uso de uma correção que toma como base o ajuste da irradiação solar incidente no topo da atmosfera em função do percurso do Sol na abóbada celeste para os horizontes futuros (Equação 2).

$$Persistência = P_{cs_i} * \left(\frac{P_{real_{i-1}}}{P_{cs_{i-1}}} \right) \quad (2)$$

onde, P_{cs} é a potência do modelo de céu claro (neste trabalho utilizamos o modelo de céu claro de Perez et. al. 1990 e o trabalho de Almeida et. al. (2017) para conversão da irradiação solar em potência) e P_{real} a potência medida pelo gerador fotovoltaico.

2.5 Seleção dos atributos

Foram separados dois grupos de atributos para treinamento, um deles com variáveis exógenas e outro com variáveis endógenas. A primeira utiliza a série histórica das variáveis auxiliares como entrada para previsão da variável alvo enquanto que a segunda utiliza a série histórica da variável alvo como atributo de entrada. Para seleção dos atributos exógenos foi utilizado como base o trabalho de Arruda, Almeida e Martins (2024) que aplicaram duas técnicas de seleção de atributos para a mesma base de dados utilizada neste trabalho. A primeira delas é a correlação de Pearson, para avaliação da correlação linear entre as variáveis, enquanto a outra foi a informação mútua que avalia a relação não linear das variáveis com a variável alvo. Com base nisso foram criados dois grupos de atributos de entrada:

- Grupo Exógeno: Irradiação solar global incidente no plano horizontal, temperatura ambiente, velocidade do vento, umidade relativa, ângulos zenitais e azimutais
- Grupo Endógeno: Potência, ângulo zenital e azimutal



2.6 Separação da base de dados

A base de dados foi dividida em três grupos, sendo: treino, teste e validação. Para evitar que ocorresse vazamento de dados (*data leakage*) foram separados os anos de 2018 a 2020 para o treinamento do modelo. Dados coletados em 2021 foram separados da seguinte maneira: a primeira metade dos meses (dias 1 a 15) foram utilizadas para validação, enquanto que a segunda metade (dias 16 a 30 ou 31) foram utilizados para testes. O modelo foi treinado para realizar as previsões somente em períodos em que a potência do gerador seja diferente de zero e ângulos zenitais inferiores a 70 graus para evitar os períodos de nascer e pôr do Sol uma vez que a produção do gerador é praticamente irrelevante e as incertezas nas observações são maiores em razão da geometria de incidência solar e dos processos radiativos na atmosfera com massa ótica elevada nesses horários.

Os dados foram normalizados da seguinte forma: os ângulos zenital e azimutal foram convertidos pelos seus cossenos e senos respectivamente, a umidade relativa foi convertida para sua versão decimal, a irradiação global foi convertida em índice de claridade (K_t) utilizando a razão da irradiação medida em superfície pela irradiação no topo da atmosfera, os valores de temperatura e velocidade do vento foram normalizados entre 0 e 1 pelo algoritmo *MinMaxScaler* do *Scikitlearn* e as medições de potência foram divididas pela capacidade instalada do gerador (156 kW).

Modelos baseados em LSTM necessitam que os dados sejam convertidos para um formato tridimensional contendo a quantidade de amostras, os *timesteps* (sequência de medições) e as características (quantidade de atributos que serão utilizados), formando assim mini séries temporais.

Durante o treinamento dos modelos foram utilizadas duas técnicas auxiliares. A primeira é um algoritmo disponível na biblioteca Keras chamado de *Early Stopping* cuja função é evitar que o modelo fique super ajustado ao treinamento (*Overfitting*). A segunda técnica, baseada no algoritmo de força bruta (*Grid Search*), visa identificar os melhores hiperparâmetros a serem adotados na topologia das redes. Foram avaliados os timesteps variando entre 24, 48 e 72, e a quantidade de unidades LSTM variando entre 100, 200 e



300. Cada configuração foi treinada 10 vezes e calculada a média dos valores de erro. A configuração selecionada foi com 72 timesteps e 300 unidades

2.7 Métricas para avaliação de incertezas da modelagem

Para avaliar o modelo foram utilizadas as seguintes métricas de erro estatísticos: RMSE (Eq. 3), Viés (Eq. 4), Correlação de Pearson e Skill Score (Eq. 5). Onde x são os valores medidos e y os valores previstos.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - x_i)^2} \quad (3)$$

$$Viés = \frac{\bar{y} - \bar{x}}{\bar{x}} \quad (4)$$

$$Skill\ Score = 1 - \frac{RMSE_{modelo}}{RMSE_{persistência}} \quad (5)$$

3. RESULTADOS E CONCLUSÃO

A Tabela 1 apresenta as métricas utilizadas para avaliar os desvios apresentados pelas previsões nos horizontes futuros. Também foram adicionados o resultado obtido por Arruda, Almeida e Martins (2024), que utilizaram a mesma base para um modelo LSTM *vanilla*. Inicialmente podemos notar que o modelo Encoder Decoder LSTM utilizando das mesmas variáveis que o modelo LSTM, é superior nos três horizontes de previsão tendo seu RMSE variando entre 5,96% até 6,72% enquanto que o LSTM variou entre 6,00% até 7,46%. Contudo ambos os modelos não superaram a persistência no horizonte de 1 hora, obtendo *skill score* de -15,37% e -17,65%. Já a versão do Encoder Decoder com variáveis endógenas superou os dois modelos citados anteriormente, obtendo RMSE variando de 4,46% a 6,15%, além de ser o único a obter o *skill score* positivo em todos os horizontes de previsão.

Para auxiliar na análise também foram feitos um Diagrama de Taylor e Diagrama Target (Figura 2). Nele notamos que ao comparar os modelos em seus respectivos horizontes de previsão, o modelo Encoder Decoder LSTM com variáveis endógenas é o que se destaca como o que apresenta menor desvio em relação a potência verificada no horizonte de previsão.




Tabela 1. Resultado das métricas de erros após o treinamento dos modelos e comparação com a literatura

ID	Horizonte de previsão	RMSE	Correlação	Viés	Skill Score
Encoder Decoder	1 Hora	5,96%	0,86	12,67%	-15,37%
LSTM Grupo Exógeno	2 Horas	6,55%	0,80	8,42%	27,84%
	3 Horas	6,72%	0,79	6,73%	50,34%
Encoder Decoder	1 Hora	4,46%	0,90	-0,20%	13,67%
LSTM Grupo Endógeno	2 Horas	5,67%	0,84	-0,04%	37,51%
	3 Horas	6,15%	0,81	-0,26%	54,51%
LSTM (Arruda, Almeida e Martins 2024)	1 Hora	6,00%	0,60	-0,15%	-17,65%
	2 Horas	6,81%	0,66	0,03%	11,56%
	3 Horas	7,46%	0,70	-3,50%	22,29%

Fonte: Autoria Própria

Figura 2. Diagrama de Taylor e Target para avaliação dos modelos treinados e persistência

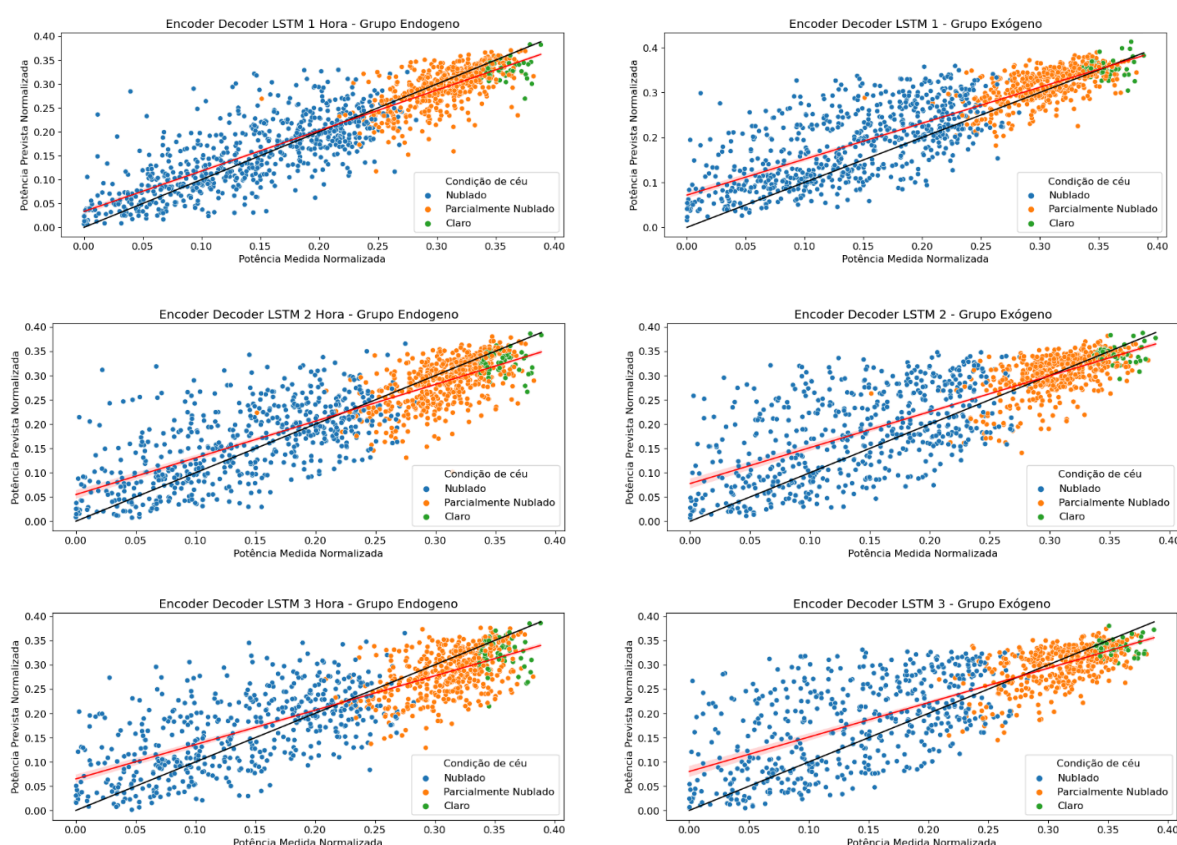


Fonte: Autoria Própria

Também foram analisados como os modelos Encoder Decoder se comportam em condição de céu claro ($kt > 0,7$), céu parcialmente nublado ($0,7 > kt > 0,4$) e céu nublado ($kt < 0,4$). A Figura 3 apresenta o gráfico de dispersão para cada horizonte de previsão separando os dados pelas condições de céu citadas anteriormente. A Tabela 2 traz as métricas estatísticas dos dois modelos. A partir dos resultados, podemos destacar ligeira vantagem na utilização de atributos exógenos em condições de céu claro e parcialmente nublado, contudo em condições de céu nublado sua performance cai drasticamente com

RMSE variando entre 8,28% e 8,72%, além de superar a persistência somente no horizonte de previsão de três horas. A versão com atributos endógenos surge como uma alternativa mais estável nas três condições, tendo *skill score* negativo somente no horizonte de previsão de 1 hora em condição de céu claro e em condição de céu nublado o seu *skill score* variou entre 9,26% e 30,25%.

Figura 3. Gráficos de dispersão dos modelos com atributos endógenos à esquerda e atributos exógenos à direita. Os horizontes de previsão estão apresentados por linhas.



Fonte: Autoria própria

Por fim, vale ressaltar que o modelo Encoder Decoder LSTM utilizando da série histórica de potência como um dos atributos de entrada, foi o único modelo que superou o modelo de persistência no horizonte de previsão de três horas, apresentando *skill score* de 13,67%, 37,51% e 54,51%. Além disso, o modelo se mostrou estável para as três condições de céu consideradas no trabalho, mesmo sendo exposto a uma localidade com condições atmosféricas desafiadoras com elevada concentração de aerossóis durante a estação seca do ano. Como estudos futuros, testaremos o modelo em diferentes localidades do Brasil, além



de retreiná-lo utilizando uma técnica conhecida como *transfer learning* (transferência de aprendizado) para comparação e avaliação de seu desempenho.

Tabela 2. Resultado das métricas de erros em condições de céu claro, nublado e parcialmente nublado.

Condição de céu	ID	Horizonte de previsão	RMSE	Corr	Bias	SS
Céu Claro	Encoder	1 Hora	2,21%	0,14	0,20%	10,99%
	Decoder LSTM	2 Horas	2,36%	0,13	-3,31%	49,05%
	Grupo Exógeno	3 Horas	2,71%	0,17	-5,54%	71,75%
	Encoder	1 Hora	3,19%	0,19	-6,51%	-28,44%
	Decoder LSTM	2 Horas	3,82%	0,05	-7,65%	17,35%
	Grupo Endógeno	3 Horas	4,63%	0,04	-8,53%	51,72%
Céu Parcialment e Nublado	Encoder	1 Hora	3,23%	0,71	4,02%	15,46%
	Decoder LSTM	2 Horas	3,47%	0,70	-0,46%	43,56%
	Grupo Exógeno	3 Horas	3,70%	0,66	-3,13%	62,16%
	Encoder	1 Hora	3,53%	0,88	-4,48%	7,52%
	Decoder LSTM	2 Horas	4,49%	0,84	-6,66%	27,06%
	Grupo Endógeno	3 Horas	5,02%	0,73	-8,44%	48,66%
Céu Nublado	Encoder	1 Hora	8,28%	0,81	34,91%	-36,05%
	Decoder LSTM	2 Horas	8,72%	0,76	29,49%	-8,72%
	Grupo Exógeno	3 Horas	8,67%	0,71	28,55%	14,03%
	Encoder	1 Hora	5,52%	0,81	7,75%	9,26%
	Decoder LSTM	2 Horas	6,69%	0,74	13,77%	16,61%
	Grupo Endógeno	3 Horas	7,03%	0,69	17,34%	30,25%

Fonte: Autoria própria

4. AGRADECIMENTOS

Os autores agradecem à FAPESP pelo auxílio da bolsa de mestrado disponibilizado no processo 2022/10281-6, e ao Instituto Nacional de Mudanças Climáticas (INCT-MC) - processos CNPq 465501/2014- 1, FAPESP 2014/50848-9 e CAPES/FAPS N° 16/2014. Os autores registram o agradecimento à UNIFESP e à USP.

REFERÊNCIAS BIBLIOGRÁFICAS





ABSOLAR. **Energia Solar Fotovoltaica no Brasil: infográfico** ABSOLAR. n. 67, p.2, 2024

ALMEIDA, M. P. **Implicações técnicas da inserção em grande escala da geração solar fotovoltaica na matriz elétrica**. 2017. 191p. Tese (Doutorado em Ciências) - Programa de Pós-Graduação em Energia da Universidade de São Paulo, São Paulo, 2017

ALMEIDA, M. P. et al. Comparative study of PV power forecast using parametric and nonparametric PV models. **Solar Energy**, v. 155, p. 854-866, 2017.

ARRUDA, F. V.; ALMEIDA, M. P.; MARTINS, F. R. Estudo De Caso De Lstm E Autoencoder Lstm Para Previsão A Curto Prazo Utilizando Múltiplas Séries Temporais. **Anais do Congresso Brasileiro de Energia Solar X**, Natal, RN, Brasil

BET, L. G. et al. Estudo Sobre O Impacto Dos Aerossóis Atmosféricos No Fator Espectral De Módulos Fotovoltaicos Em São Paulo. **Revista Brasileira de Energia Solar**, v. 13, n. 2, p. 146-156, 2022.

DIAGNE, M. et al. Review of solar irradiance forecasting methods and a proposition for small-scale insular grids. **Renewable and Sustainable Energy Reviews**, v. 27, p. 65-76, 2013.

GOODFELLOW, I., YOSHUA B., and AARON C.. **Deep learning**. MIT press, 2016.

HOCHREITER, S., e JÜRGEN S.. Long short-term memory. **Neural computation** 9.8 (1997): 1735-1780.

PEREIRA, E. B. et al. **Atlas brasileiro de energia solar**. 2. ed. São José dos Campos: INPE, 2017. ISBN 978-85-17-00089-8. 2017.

PEREZ, R et al. Modeling daylight availability and irradiance components from direct and global irradiance. **Solar Energy**, v. 44, n. 5, p. 271-289, 1990.

RAJAGUKGUK, R. A.; RAMADHAN, R. AA; LEE, H. A review on deep learning models for forecasting time series data of solar irradiance and photovoltaic power. **Energies**, v. 13, n. 24, p. 6623, 2020.

SABRI, M.; EL HASSOUNI, M. Photovoltaic power forecasting with a long short-term memory autoencoder networks. **Soft Computing**, v. 27, n. 15, p. 10533-10553, 2023.

